

"Playing" con diferentes clasificadores y datasets

Haessler Joan Ortiz Moncada

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Curso: Big Data

10 de septiembre de 2025

1. Introducción

Este documento presenta el desarrollo del **Assignment #4** del curso de Big Data y documenta los hallazgos y análisis correspondientes, haciendo uso de tres métricas e incorporando gráficos adecuados que permitan evidenciar y sustentar los resultados. El **Assignment #4** propone experimentar con diversos modelos de clasificación sobre distintos conjuntos de datos (**Blobs**, **Gaussian Quartiles** y **Moons**), con diferentes tamaños de muestra y niveles de ruido inducido.

2. Metodología


Se desarrolla conforme a lo establecido en el **Assignment #4**, aunque con algunas variaciones en la presentación. En aquel caso se solicitaba que todo el trabajo se realizara en un único documento o archivo de Colab; en cambio, aquí se optó por efectuar la codificación en dicho entorno y presentar los hallazgos y el compendio de resultados mediante un informe escrito. Se emplearon principalmente Google Colab y Python, haciendo uso de los paquetes **os**, **pandas**, **scikit-learn**, **matplotlib** y **seaborn**. También se tuvo en cuenta manejar el mismo escenario de aleatoriedad (semiila) para poder replicar los resultados.

Básicamente, lo que se hizo fue ir desarrollando en Colab el código correspondiente y de manera paralela documentar los hallazgos y resultados en este informe. Por último, el código fuente implementado en Colab, los datos utilizados y el archivo de este informe se encuentran en la carpeta `taller_4` del repositorio de GitHub [bigdata_repositorio](#).


3. Escenario 1: binario vs. clasificación multiclase

En esta sección se construyeron tres conjuntos de datos: uno binario (dos clases) y otros dos con cinco y veinte clases, respectivamente. Como el **Assignment #4** no especificó el tamaño, se fijaron en 1,000 registros cada uno. Para su construcción se emplearon datos tipo **Blobs**, cuyas observaciones se distribuyen como puntos en el plano cartesiano;

cada clase agrupa sus puntos en una región del espacio. Los datos se dividieron en entrenamiento, validación y prueba en proporciones de 60 %, 20 % y 20 %, respectivamente; además, se aplicó estratificación para que cada partición mantuviera la misma distribución de clases que el dataset padre. La Figura 1 muestra como las frecuencias de las clases para el dataset binario y para el de cinco clases, mientras la Figura 2 muestra la frecuencia del dataset que cse clasifica en 20 clases.



(a) Frecuencia clases dataset binario.



(b) Frecuencia clases dataset de cinco clases.

Figura 1: Frecuencia clases datasets binario y de cinco clases.




Figura 2: Frecuencia clases dataset de veinte clases.

3.1. Probando con distintos clasificadores

En este y en los siguientes escenarios, se evaluará cómo distintos clasificadores predicen las clases de cada conjunto de datos, explorando los hiperparámetros configurables de cada modelo. Posteriormente, se seleccionará la combinación de hiperparámetros que ofrezca el mejor desempeño predictivo según las métricas **Accuracy**, **Recall** y **F1-Score**.

1. **Vecinos más cercanos (k-NN).** Probando con un rango de 1 a 30 vecinos para cada uno de los datasets conformados, se definio que el mejor desempeño se obtuvo con los siguientes hiperparámetros:

- **Dataset binario.** 1 vecinos.
- **Dataset con cinco clases.** 8 vecinos.
- **Dataset con veinte clases.** 19 vecinos.

Respecto al desempeño obtenido en cada uno de los modelos se tienen los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.86	0.80	0.83	15
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.96	0.97	0.97	76
Accuracy			0.97	200
Macro avg	0.96	0.95	0.96	200
Weighted avg	0.97	0.97	0.97	200
(c) 20 clases				
0	1.00	1.00	1.00	8
1	0.91	1.00	0.95	20
2	0.67	0.53	0.59	15
3	0.80	0.40	0.53	10
4	1.00	1.00	1.00	7
5	0.52	0.67	0.59	18
6	1.00	1.00	1.00	9
7	0.56	0.77	0.65	13
8	0.83	1.00	0.91	20
9	0.00	0.00	0.00	2
10	0.75	1.00	0.86	6
11	0.71	0.71	0.71	7
12	1.00	1.00	1.00	6
13	0.75	0.50	0.60	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.65	0.65	0.65	20
17	0.00	0.00	0.00	1
18	0.00	0.00	0.00	2

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
19	1.00	0.95	0.98	21
Accuracy			0.79	200
Macro avg	0.66	0.65	0.65	200
Weighted avg	0.78	0.79	0.78	200

Tabla 1: Reportes de clasificación k-NN en tres escenarios (2, 5 y 20 clases).

2. **Arbol de decisión.** Se buscó la mejor configuración de hiperparámetros en el siguiente marco:

Parámetro	Descripción	Valores probados
max_depth	Profundidad máxima del árbol	{None, 5, 10, 15, 20}
min_samples_split	Mín. muestras para dividir un nodo interno	{2, 5, 10}
min_samples_leaf	Mín. muestras por hoja	{1, 2, 4}

Tabla 2: Rangos de hiperparámetros evaluados para `DecisionTreeClassifier`.

Con base en esta búsqueda se obtuvieron las siguientes mejores configuraciones de hiperparámetros para cada dataset:

Clases	max_depth	min_samples_leaf	min_samples_split
2	None	1	2
5	5	1	2
20	10	1	5

Tabla 3: Mejores hiperparámetros encontrados para **Arbol de decisión**.

Respecto al desempeño obtenido en cada uno de los modelos se tienen los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.71	0.67	0.69	15
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.94	0.95	0.94	76

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
Accuracy			0.95	200
Macro avg	0.93	0.92	0.93	200
Weighted avg	0.95	0.95	0.95	200
(c) 20 clases				
0	1.00	0.88	0.93	8
1	0.91	1.00	0.95	20
2	0.53	0.60	0.56	15
3	0.80	0.40	0.53	10
4	1.00	1.00	1.00	7
5	0.50	0.72	0.59	18
6	1.00	1.00	1.00	9
7	0.46	0.46	0.46	13
8	0.91	1.00	0.95	20
9	1.00	0.50	0.67	2
10	0.75	1.00	0.86	6
11	1.00	0.86	0.92	7
12	0.86	1.00	0.92	6
13	0.80	0.67	0.73	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.76	0.65	0.70	20
17	1.00	1.00	1.00	1
18	1.00	0.50	0.67	2
19	1.00	0.81	0.89	21
Accuracy			0.79	200
Macro avg	0.81	0.75	0.76	200
Weighted avg	0.81	0.79	0.79	200

Tabla 4: Reportes de clasificación — Árbol de decisión (2, 5 y 20 clases).

3. **Máquinas de vectores de soporte (SVM por sus siglas en inglés).** Para este clasificador se buscó la mejor configuración de hiperparámetros probando los siguientes valores:

Parámetro	Descripción	Valores probados
C	Parámetro de regularización.	{0.1, 1, 10}
kernel	Tipo de núcleo usado por el algoritmo SVM.	{ linear , rbf }
gamma	Coefficiente del kernel.	{ scale , auto , 0.1, 1}

Tabla 5: Espacio de hiperparámetros evaluado para SVM.

Los mejores hiperparámetros encontrados para cada dataset, fueron los siguientes:

Con los mejores hiperparámetros encontrados, se obtuvieron los siguientes resultados:

Clases	C	gamma	kernel
2	0.1	scale	linear
5	0.1	scale	linear
20	0.1	scale	linear

Tabla 6: Mejores hiperparámetros SVM.

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.86	0.80	0.83	15
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.96	0.97	0.97	76
Accuracy			0.97	200
Macro avg	0.96	0.95	0.96	200
Weighted avg	0.97	0.97	0.97	200
(c) 20 clases				
0	1.00	1.00	1.00	8
1	0.95	1.00	0.98	20
2	0.60	0.60	0.60	15
3	0.80	0.40	0.53	10
4	1.00	1.00	1.00	7
5	0.53	0.56	0.54	18
6	1.00	1.00	1.00	9
7	0.57	0.62	0.59	13
8	0.91	1.00	0.95	20
9	1.00	1.00	1.00	2
10	0.75	1.00	0.86	6
11	1.00	0.71	0.83	7
12	1.00	1.00	1.00	6
13	0.83	0.83	0.83	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.58	0.70	0.64	20
17	1.00	1.00	1.00	1
18	1.00	0.50	0.67	2
19	1.00	0.95	0.98	21
Accuracy			0.81	200

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
Macro avg	0.83	0.79	0.80	200
Weighted avg	0.82	0.81	0.81	200

Tabla 7: Reportes de clasificación — **SVM** (2, 5 y 20 clases).

4. **Perceptrón multicapa (MLP por sus siglas en inglés)**. Para este clasificador se buscó la mejor configuración de hiperparámetros probando con los siguientes valores:

Parámetro	Descripción	Valores probados
hidden_layer_sizes	Tamaño(s) de capa(s) oculta(s)	(50,), (100,), (50, 50)
activation	Función de activación	tanh , relu
solver	Optimizador para los pesos	adam
alpha	Regularización L2	0.0001, 0.001
learning_rate_init	Tasa de aprendizaje inicial	0.001, 0.01
max_iter	Iteraciones máximas	200, 500

Tabla 8: Espacio de hiperparámetros evaluado para MLP.

Con base en esta búsqueda se obtuvieron las siguientes mejores configuraciones de hiperparámetros para cada dataset:

Clases	hidden_layer_sizes	activation	solver	alpha	learning_rate_init	max_iter
2	(50,)	tanh	adam	0.0001	0.001	200
5	(50, 50)	tanh	adam	0.0001	0.01	200
20	(100,)	tanh	adam	0.0001	0.001	500

Tabla 9: Mejores hiperparámetros MLP.

Con la configuraciones de hiperparámetros encontradas, se obtuvieron los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.86	0.80	0.83	15
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.96	0.97	0.97	76
Accuracy			0.97	200

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
Macro avg	0.96	0.95	0.96	200
Weighted avg	0.97	0.97	0.97	200
(c) 20 clases				
0	1.00	1.00	1.00	8
1	0.95	1.00	0.98	20
2	0.60	0.60	0.60	15
3	0.75	0.60	0.67	10
4	1.00	1.00	1.00	7
5	0.56	0.56	0.56	18
6	1.00	1.00	1.00	9
7	0.57	0.62	0.59	13
8	0.95	1.00	0.98	20
9	1.00	1.00	1.00	2
10	0.75	1.00	0.86	6
11	1.00	0.86	0.92	7
12	1.00	1.00	1.00	6
13	0.83	0.83	0.83	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.59	0.65	0.62	20
17	1.00	1.00	1.00	1
18	1.00	0.50	0.67	2
19	1.00	0.95	0.98	21
Accuracy			0.82	200
Macro avg	0.83	0.80	0.81	200
Weighted avg	0.82	0.82	0.82	200

Tabla 10: Reportes de clasificación — **MLP** (2, 5 y 20 clases).

5. Análisis de resultados.

- **Tendencia general.** Con 2 clases, todos los modelos aciertan casi perfecto. Con 5 clases siguen muy altos. Al pasar a **20 clases**, la exactitud baja para todos (≈ 0.79 – 0.82) por mayor solapamiento entre clases y menos ejemplos por clase.
- **K-NN.** Excelente con pocas clases, pero cae más con 20 clases: encontrar vecinos “correctos” se vuelve difícil en un espacio de variables fijo.
- **Árbol de decisión.** También disminuye con más clases. Al dividir con cortes alineados a ejes, requiere muchos *splits* y puede sobreajustar cuando hay pocos datos por clase.
- **SVM.** Con 2 y 5 clases, el *kernel* lineal funciona muy bien (clases bastante separables). Con 20 clases suele requerir *RBF* para fronteras no lineales y se mantiene competitivo.
- **MLP.** Rinde muy bien en general. Con 20 clases suele estar entre los mejores; puede necesitar redes más grandes y más iteraciones para converger.
- **“Mejor” por conjunto.**
 - **2 clases:** todos al tope (≈ 1.00).

- **5 clases:** K-NN y SVM lideran; Árbol y MLP muy cerca.
- **20 clases:** MLP o K-NN encabezan según el corrido; diferencias pequeñas (≈ 0.79 – 0.82).
- **Variabilidad por clase (20 clases).** Se observan clases minoritarias con precisión/recall/f1 bajos e incluso métricas indefinidas cuando no se predice alguna clase, lo que apunta a **desbalance** y **solapamiento** entre clases.

Posibles mejoras en la predicción del dataset de 20 clases

- Tratar el **desbalance** (pesos por clase, sobremuestreo/SMOTE).
- Ampliar y afinar** hiperparámetros: k en K-NN; poda/profundidad en Árbol; C y γ en SVM; capas, neuronas, iteraciones y *early stopping* en MLP.
- Enriquecer las características** o transformar las actuales para mejorar la separabilidad.
- Probar **ensambles** (bagging/boosting) y **calibración** de probabilidades.

En síntesis: con pocas clases, casi todo funciona perfecto; con 20 clases, la tarea se complica y destacan los modelos que aprenden **fronteras no lineales** y manejan mejor el **desbalance** (MLP/SVM), aunque K-NN puede empatar cuando las clases quedan bien definidas.

Adicionalmente el gráfico mostrado en la Figura 3 a continuación, permite visualizar como se trazaron los diferentes límites de clasificación definidos por cada modelo y para cada dataset.




Figura 3: Matriz de fronteras de decisión.




Figura 3: Matriz de fronteras de decisión.

4. Escenario 2: grandes datasets vs pequeños datasets

Este escenario aborda un desarrollo muy similar al del anterior: se construyen conjuntos de datos, se dividen en subconjuntos de entrenamiento, validación y prueba, conservando la proporción de clases de los datasets originales y conservando la proporción del escenario anterior, y posteriormente se implementan los mismos modelos de clasificación del escenario previo. La diferencia principal radica en la forma de construir los conjuntos de datos: aquí los datos son de tipo **Quartiles Gaussian**; cada conjunto tiene cuatro clases y se generan cinco datasets con los siguientes tamaños: 10^2 , 10^3 , 10^4 , 10^5 , 10^6 . A diferencia del anterior escenario, aquí si se va a generar la misma cantidad de registros para cada clase en cada dataset.

1. **Vecinos más cercanos (k-NN)**. Probando con un rango de 1 a 30 vecinos (al igual que en el anterior escenario) para cada uno de los datasets conformados, se obtuvo que el mejor desempeño para todos los datasets fue con el número de vecinos igual a 1. Los resultados obtenidos fueron los siguientes:

Tamaño (muestras)	Línea	Precision	Recall	F1-score	Support
100	Clase 0	0.67	0.80	0.73	5
	Clase 1	0.33	0.20	0.25	5
	Clase 2	0.36	0.80	0.50	5
	Clase 3	0.00	0.00	0.00	5
	Accuracy	—	—	0.45	20
	Macro avg	0.34	0.45	0.37	20
	Weighted avg	0.34	0.45	0.37	20

Continúa en la siguiente página

Tamaño (muestras)	Línea	Precision	Recall	F1-score	Support
1 000	Clase 0	0.98	0.94	0.96	50
	Clase 1	0.90	0.86	0.88	50
	Clase 2	0.80	0.90	0.85	50
	Clase 3	0.94	0.90	0.92	50
	Accuracy	—	—	0.90	200
	Macro avg	0.90	0.90	0.90	200
	Weighted avg	0.90	0.90	0.90	200
10 000	Clase 0	0.99	0.98	0.99	500
	Clase 1	0.97	0.98	0.98	500
	Clase 2	0.97	0.98	0.97	500
	Clase 3	0.98	0.98	0.98	500
	Accuracy	—	—	0.98	2 000
	Macro avg	0.98	0.98	0.98	2 000
	Weighted avg	0.98	0.98	0.98	2 000
100 000	Clase 0	1.00	1.00	1.00	5 000
	Clase 1	0.99	0.99	0.99	5 000
	Clase 2	0.99	0.99	0.99	5 000
	Clase 3	0.99	0.99	0.99	5 000
	Accuracy	—	—	0.99	20 000
	Macro avg	0.99	0.99	0.99	20 000
	Weighted avg	0.99	0.99	0.99	20 000
1 000 000	Clase 0	1.00	1.00	1.00	50 000
	Clase 1	1.00	1.00	1.00	50 000
	Clase 2	1.00	1.00	1.00	50 000
	Clase 3	1.00	1.00	1.00	50 000
	Accuracy	—	—	1.00	200 000
	Macro avg	1.00	1.00	1.00	200 000
	Weighted avg	1.00	1.00	1.00	200 000

Tabla 11: K-NN: métricas.

2. **Arbol de decisión.** Se buscó la mejor configuración de hiperparámetros en relación con el desempeño de los modelos, el rango de búsqueda para este escenario, fue el mismo que para el anterior, es decir, los mismos establecidos en la ???. La mejor configuración para cada dataset fue la siguiente:

Tamaño (muestras)	max_depth	min_samples_leaf	min_samples_split
100	None	1	2
1 000	None	1	2
10 000	15	1	2
100 000	None	1	2
1 000 000	20	1	2

Tabla 12: Mejores hiperparámetros Arbol de decisión.

Las métricas de desempeño correspondientes se muestran a continuación:

Tamaño (muestras)	Línea	Precision	Recall	F1-score	Support
100	Clase 0	1.00	0.80	0.89	5
	Clase 1	0.50	0.40	0.44	5
	Clase 2	0.62	1.00	0.77	5
	Clase 3	1.00	0.80	0.89	5
	Accuracy	—	—	0.75	20
	Macro avg	0.78	0.75	0.75	20
	Weighted avg	0.78	0.75	0.75	20
1 000	Clase 0	0.96	0.96	0.96	50
	Clase 1	0.95	0.78	0.86	50
	Clase 2	0.75	0.98	0.85	50
	Clase 3	0.98	0.86	0.91	50
	Accuracy	—	—	0.90	200
	Macro avg	0.91	0.89	0.90	200
	Weighted avg	0.91	0.90	0.90	200
10 000	Clase 0	0.98	0.98	0.98	500
	Clase 1	0.96	0.96	0.96	500
	Clase 2	0.95	0.94	0.95	500
	Clase 3	0.97	0.97	0.97	500
	Accuracy	—	—	0.96	2 000
	Macro avg	0.96	0.96	0.96	2 000
	Weighted avg	0.96	0.96	0.96	2 000
100 000	Clase 0	0.99	0.99	0.99	5 000
	Clase 1	0.99	0.99	0.99	5 000
	Clase 2	0.98	0.98	0.98	5 000
	Clase 3	0.99	0.99	0.99	5 000
	Accuracy	—	—	0.99	20 000
	Macro avg	0.99	0.99	0.99	20 000
	Weighted avg	0.99	0.99	0.99	20 000
1 000 000	Clase 0	1.00	1.00	1.00	50 000
	Clase 1	0.99	1.00	1.00	50 000
	Clase 2	0.99	0.99	0.99	50 000
	Clase 3	1.00	1.00	1.00	50 000
	Accuracy	—	—	1.00	200 000
	Macro avg	1.00	1.00	1.00	200 000
	Weighted avg	1.00	1.00	1.00	200 000

Tabla 13: Árbol de decisión: métricas de desempeño por dataset.

3. **SVM.** Buscando la mejor configuración de hiperparámetros en relación con el desempeño de los modelos, se optó por probar con las siguientes posibilidades:

Se tuvieron las siguientes mejores configuraciones para cada dataset:

Las métricas de desempeño correspondientes se muestran a continuación:

5. Conclusiones