

"Playing" con diferentes clasificadores y datasets

Haessler Joan Ortiz Moncada

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Curso: Big Data

12 de septiembre de 2025

1. Introducción

Este documento presenta el desarrollo del **Assignment #4** del curso de Big Data y documenta los hallazgos y análisis correspondientes, haciendo uso de tres métricas e incorporando gráficos adecuados que permitan evidenciar y sustentar los resultados. El **Assignment #4** propone experimentar con diversos modelos de clasificación sobre distintos conjuntos de datos (**Blobs**, **Gaussian Quartiles** y **Moons**), con diferentes tamaños de muestra y niveles de ruido inducido.

2. Metodología


Se desarrolla conforme a lo establecido en el **Assignment #4**, aunque con algunas variaciones en la presentación. En aquel caso se solicitaba que todo el trabajo se realizara en un único documento o archivo de Colab; en cambio, aquí se optó por efectuar la codificación en dicho entorno y presentar los hallazgos y el compendio de resultados mediante un informe escrito. Se emplearon principalmente Google Colab y Python, haciendo uso de los paquetes **os**, **pandas**, **scikit-learn**, **matplotlib** y **seaborn**. También se tuvo en cuenta manejar el mismo escenario de aleatoriedad (semiila) para poder replicar los resultados.

Básicamente, lo que se hizo fue ir desarrollando en Colab el código correspondiente y de manera paralela documentar los hallazgos y resultados en este informe. El archivo de este informe se encuentran en la carpeta `taller_4` del repositorio de GitHub [bigdata_repositorio](#).


3. Escenario 1: binario vs. clasificación multiclase

En esta sección se construyeron tres conjuntos de datos: uno binario (dos clases) y otros dos con cinco y veinte clases, respectivamente. Como el **Assignment #4** no especificó el tamaño, se fijaron en 1,000 registros cada uno. Para su construcción se emplearon datos tipo **Blobs**, cuyas observaciones se distribuyen como puntos en el plano cartesiano;

cada clase agrupa sus puntos en una región del espacio. Los datos se dividieron en entrenamiento, validación y prueba en proporciones de 60 %, 20 % y 20 %, respectivamente; además, se aplicó estratificación para que cada partición mantuviera la misma distribución de clases que el dataset padre. La Figura 1 muestra como las frecuencias de las clases para el dataset binario y para el de cinco clases, mientras la Figura 2 muestra la frecuencia del dataset que cse clasifica en 20 clases.



(a) Frecuencia clases dataset binario.



(b) Frecuencia clases dataset de cinco clases.

Figura 1: Frecuencia clases datasets binario y de cinco clases.




Figura 2: Frecuencia clases dataset de veinte clases.

3.1. Probando con distintos clasificadores

En este y en los siguientes escenarios, se evaluará cómo distintos clasificadores predicen las clases de cada conjunto de datos, explorando los hiperparámetros configurables de cada modelo. Posteriormente, se seleccionará la combinación de hiperparámetros que ofrezca el mejor desempeño predictivo según las métricas **Accuracy**, **Recall** y **F1-Score**. Cabe

acalarar que fue con el conjunto de validación con el que se encontraron los mejores hiperparámetros en todos los escenarios y para todos los modelos.

1. **Vecinos más cercanos (k-NN).** Probando con un rango de 1 a 30 vecinos para cada uno de los datasets conformados, se definió que el mejor desempeño se obtuvo con los siguientes hiperparámetros:

- **Dataset binario.** 1 vecinos.
- **Dataset con cinco clases.** 8 vecinos.
- **Dataset con veinte clases.** 19 vecinos.

Respecto al desempeño obtenido en cada uno de los modelos se tienen los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.86	0.80	0.83	15
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.96	0.97	0.97	76
Accuracy			0.97	200
Macro avg	0.96	0.95	0.96	200
Weighted avg	0.97	0.97	0.97	200
(c) 20 clases				
0	1.00	1.00	1.00	8
1	0.91	1.00	0.95	20
2	0.67	0.53	0.59	15
3	0.80	0.40	0.53	10
4	1.00	1.00	1.00	7
5	0.52	0.67	0.59	18
6	1.00	1.00	1.00	9
7	0.56	0.77	0.65	13
8	0.83	1.00	0.91	20
9	0.00	0.00	0.00	2
10	0.75	1.00	0.86	6
11	0.71	0.71	0.71	7
12	1.00	1.00	1.00	6
13	0.75	0.50	0.60	6
14	1.00	0.88	0.93	8

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
15	0.00	0.00	0.00	1
16	0.65	0.65	0.65	20
17	0.00	0.00	0.00	1
18	0.00	0.00	0.00	2
19	1.00	0.95	0.98	21
Accuracy			0.79	200
Macro avg	0.66	0.65	0.65	200
Weighted avg	0.78	0.79	0.78	200

Tabla 1: Reportes de clasificación k-NN SC1.

2. **Arbol de decisión.** Se buscó la mejor configuración de hiperparámetros en el siguiente marco:

Parámetro	Descripción	Valores probados
max_depth	Profundidad máxima del árbol	{None, 5, 10, 15, 20}
min_samples_split	Mín. muestras para dividir un nodo interno	{2, 5, 10}
min_samples_leaf	Mín. muestras por hoja	{1, 2, 4}

Tabla 2: Búsqueda de hiperparámetros Arbol de de Decisión SC1.

Con base en esta búsqueda se obtuvieron las siguientes mejores configuraciones de hiperparámetros para cada dataset:

Clases	max_depth	min_samples_leaf	min_samples_split
2	None	1	2
5	5	1	2
20	10	1	5

Tabla 3: Mejores hiperparámetros encontrados para Árbol de decisión SC1.

Respecto al desempeño obtenido en cada uno de los modelos se tienen los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.71	0.67	0.69	15

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.94	0.95	0.94	76
Accuracy				0.95
Macro avg	0.93	0.92	0.93	200
Weighted avg	0.95	0.95	0.95	200
(c) 20 clases				
0	1.00	0.88	0.93	8
1	0.91	1.00	0.95	20
2	0.53	0.60	0.56	15
3	0.80	0.40	0.53	10
4	1.00	1.00	1.00	7
5	0.50	0.72	0.59	18
6	1.00	1.00	1.00	9
7	0.46	0.46	0.46	13
8	0.91	1.00	0.95	20
9	1.00	0.50	0.67	2
10	0.75	1.00	0.86	6
11	1.00	0.86	0.92	7
12	0.86	1.00	0.92	6
13	0.80	0.67	0.73	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.76	0.65	0.70	20
17	1.00	1.00	1.00	1
18	1.00	0.50	0.67	2
19	1.00	0.81	0.89	21
Accuracy				0.79
Macro avg	0.81	0.75	0.76	200
Weighted avg	0.81	0.79	0.79	200

Tabla 4: Reportes de clasificación Árbol de decisión SC1.

3. **Máquinas de vectores de soporte (SVM por sus siglas en inglés).** Para este clasificador se buscó la mejor configuración de hiperparámetros probando los siguientes valores:

Parámetro	Descripción	Valores probados
C	Parámetro de regularización.	{0.1, 1, 10}
kernel	Tipo de núcleo usado por el algoritmo SVM.	{linear, rbf}
gamma	Coeficiente del kernel.	{scale, auto, 0.1, 1}

Tabla 5: Búsqueda de hiperparámetros para SVM SC1.

Los mejores hiperparámetros encontrados para cada dataset, fueron los siguientes:

Clases	C	gamma	kernel
2	0.1	scale	linear
5	0.1	scale	linear
20	0.1	scale	linear

Tabla 6: Mejores hiperparámetros SVM SC1.

Con los mejores hiperparámetros encontrados, se obtuvieron los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.86	0.80	0.83	15
2	1.00	1.00	1.00	80
3	1.00	1.00	1.00	13
4	0.96	0.97	0.97	76
Accuracy			0.97	200
Macro avg	0.96	0.95	0.96	200
Weighted avg	0.97	0.97	0.97	200
(c) 20 clases				
0	1.00	1.00	1.00	8
1	0.95	1.00	0.98	20
2	0.60	0.60	0.60	15
3	0.80	0.40	0.53	10
4	1.00	1.00	1.00	7
5	0.53	0.56	0.54	18
6	1.00	1.00	1.00	9
7	0.57	0.62	0.59	13
8	0.91	1.00	0.95	20
9	1.00	1.00	1.00	2
10	0.75	1.00	0.86	6
11	1.00	0.71	0.83	7
12	1.00	1.00	1.00	6
13	0.83	0.83	0.83	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.58	0.70	0.64	20
17	1.00	1.00	1.00	1
18	1.00	0.50	0.67	2

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
19	1.00	0.95	0.98	21
Accuracy			0.81	200
Macro avg	0.83	0.79	0.80	200
Weighted avg	0.82	0.81	0.81	200

Tabla 7: Reportes de clasificación SVM SC1.

4. **Perceptrón multicapa (MLP por sus siglas en inglés).** Para este clasificador se buscó la mejor configuración de hiperparámetros probando con los siguientes valores:

Parámetro	Descripción	Valores probados
hidden_layer_sizes	Tamaño(s) de capa(s) oculta(s)	(50,), (100,), (50, 50)
activation	Función de activación	tanh, relu
solver	Optimizador para los pesos	adam
alpha	Regularización L2	0.0001, 0.001
learning_rate_init	Tasa de aprendizaje inicial	0.001, 0.01
max_iter	Iteraciones máximas	200, 500

Tabla 8: Búsqueda de hiperparámetros para MLP SC1.

Solo se usó un solo optimizador de pesos, conforme lo sugirió la IA de Colab. Con base en esta búsqueda se obtuvieron las siguientes mejores configuraciones de hiperparámetros para cada dataset:

Clases	hidden_layer_sizes	activation	solver	alpha	learning_rate_init	max_iter
2	(50,)	tanh	adam	0.0001	0.001	200
5	(50, 50)	tanh	adam	0.0001	0.01	200
20	(100,)	tanh	adam	0.0001	0.001	500

Tabla 9: Mejores hiperparámetros MLP SC1.

Con la configuraciones de hiperparámetros encontradas, se obtuvieron los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) 2 clases				
0	1.00	1.00	1.00	115
1	1.00	1.00	1.00	85
Accuracy			1.00	200
Macro avg	1.00	1.00	1.00	200
Weighted avg	1.00	1.00	1.00	200
(b) 5 clases				
0	1.00	1.00	1.00	16
1	0.86	0.80	0.83	15
2	1.00	1.00	1.00	80

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
3	1.00	1.00	1.00	13
4	0.96	0.97	0.97	76
Accuracy				0.97
Macro avg				200
Weighted avg				200
(c) 20 clases				
0	1.00	1.00	1.00	8
1	0.95	1.00	0.98	20
2	0.60	0.60	0.60	15
3	0.75	0.60	0.67	10
4	1.00	1.00	1.00	7
5	0.56	0.56	0.56	18
6	1.00	1.00	1.00	9
7	0.57	0.62	0.59	13
8	0.95	1.00	0.98	20
9	1.00	1.00	1.00	2
10	0.75	1.00	0.86	6
11	1.00	0.86	0.92	7
12	1.00	1.00	1.00	6
13	0.83	0.83	0.83	6
14	1.00	0.88	0.93	8
15	0.00	0.00	0.00	1
16	0.59	0.65	0.62	20
17	1.00	1.00	1.00	1
18	1.00	0.50	0.67	2
19	1.00	0.95	0.98	21
Accuracy				0.82
Macro avg				200
Weighted avg				200

Tabla 10: Reportes de clasificación MLP SC1.

5. Análisis de resultados.

- **Tendencia general.** Con 2 clases, todos los modelos aciertan casi perfecto. Con 5 clases siguen muy altos. Al pasar a **20 clases**, la exactitud baja para todos (≈ 0.79 – 0.82) por mayor solapamiento entre clases y menos ejemplos por clase.
- **K-NN.** Excelente con pocas clases, pero cae más con 20 clases: encontrar vecinos “correctos” se vuelve difícil en un espacio de variables fijo.
- **Árbol de decisión.** También disminuye con más clases. Al dividir con cortes alineados a ejes, requiere muchos *splits* y puede sobreajustar cuando hay pocos datos por clase.
- **SVM.** Con 2 y 5 clases, el *kernel* lineal funciona muy bien (clases bastante separables). Con 20 clases suele requerir *RBF* para fronteras no lineales y se mantiene competitivo.
- **MLP.** Rinde muy bien en general. Con 20 clases suele estar entre los mejores; puede necesitar redes más grandes y más iteraciones para converger.

- “Mejor” por conjunto.
 - **2 clases:** todos al tope (≈ 1.00).
 - **5 clases:** K-NN y SVM lideran; Árbol y MLP muy cerca.
 - **20 clases:** MLP o K-NN encabezan según el corrido; diferencias pequeñas (≈ 0.79 – 0.82).
- **Variabilidad por clase (20 clases).** Se observan clases minoritarias con precisión/recall/f1 bajos e incluso métricas indefinidas cuando no se predice alguna clase, lo que apunta a **desbalance** y **solapamiento** entre clases.

Posibles mejoras en la predicción del dataset de 20 clases

- a) Tratar el **desbalance** (pesos por clase, sobremuestreo/SMOTE).
- b) **Ampliar y afinar** hiperparámetros: k en K-NN; poda/profundidad en Árbol; C y γ en SVM; capas, neuronas, iteraciones y *early stopping* en MLP.
- c) **Enriquecer las características** o transformar las actuales para mejorar la separabilidad.
- d) Probar **ensambles** (bagging/boosting) y **calibración** de probabilidades.

En resumen, con pocas clases, casi todo funciona perfecto, con 20 clases, la tarea se complica y destacan los modelos que aprenden **fronteras no lineales** y manejan mejor el **desbalance** (MLP/SVM), aunque K-NN puede empatar cuando las clases quedan bien definidas.

Adicionalmente el gráfico mostrado en la Figura 3 a continuación, permite visualizar como se trazaron los diferentes límites de clasificación definidos por cada modelo y para cada dataset.




Figura 3: Matriz de fronteras de decisión.




Figura 3: Matriz de fronteras de decisión SC1.

4. Escenario 2: grandes datasets vs pequeños datasets

Este escenario aborda un desarrollo muy similar al del anterior: se construyen conjuntos de datos, se dividen en subconjuntos de entrenamiento, validación y prueba, conservando la proporción de clases de los datasets originales y conservando la proporción del escenario anterior, y posteriormente se implementan los mismos modelos de clasificación del escenario previo. La diferencia principal radica en la forma de construir los conjuntos de datos: aquí los datos son de tipo **Quartiles Gaussian**; cada conjunto tiene cuatro clases y se generan cinco datasets con los siguientes tamaños: 10^2 , 10^3 , 10^4 , 10^5 , 10^6 . A diferencia del anterior escenario, aquí si se va a generar la misma cantidad de registros para cada clase en cada dataset.

1. **Vecinos más cercanos (k-NN)**. Probando con un rango de 1 a 30 vecinos (al igual que en el anterior escenario) para cada uno de los datasets conformados, se obtuvo que el mejor desempeño para todos los datasets fue con el número de vecinos igual a 1. Los resultados obtenidos fueron los siguientes:

Tamaño (muestras)	Línea	Precision	Recall	F1-score	Support
100	Clase 0	0.67	0.80	0.73	5
	Clase 1	0.33	0.20	0.25	5
	Clase 2	0.36	0.80	0.50	5
	Clase 3	0.00	0.00	0.00	5
	Accuracy	—	—	0.45	20
	Macro avg	0.34	0.45	0.37	20
	Weighted avg	0.34	0.45	0.37	20

Continúa en la siguiente página

Tamaño (muestras)	Línea	Precision	Recall	F1-score	Support
1 000	Clase 0	0.98	0.94	0.96	50
	Clase 1	0.90	0.86	0.88	50
	Clase 2	0.80	0.90	0.85	50
	Clase 3	0.94	0.90	0.92	50
	Accuracy	—	—	0.90	200
	Macro avg	0.90	0.90	0.90	200
	Weighted avg	0.90	0.90	0.90	200
10 000	Clase 0	0.99	0.98	0.99	500
	Clase 1	0.97	0.98	0.98	500
	Clase 2	0.97	0.98	0.97	500
	Clase 3	0.98	0.98	0.98	500
	Accuracy	—	—	0.98	2 000
	Macro avg	0.98	0.98	0.98	2 000
	Weighted avg	0.98	0.98	0.98	2 000
100 000	Clase 0	1.00	1.00	1.00	5 000
	Clase 1	0.99	0.99	0.99	5 000
	Clase 2	0.99	0.99	0.99	5 000
	Clase 3	0.99	0.99	0.99	5 000
	Accuracy	—	—	0.99	20 000
	Macro avg	0.99	0.99	0.99	20 000
	Weighted avg	0.99	0.99	0.99	20 000
1 000 000	Clase 0	1.00	1.00	1.00	50 000
	Clase 1	1.00	1.00	1.00	50 000
	Clase 2	1.00	1.00	1.00	50 000
	Clase 3	1.00	1.00	1.00	50 000
	Accuracy	—	—	1.00	200 000
	Macro avg	1.00	1.00	1.00	200 000
	Weighted avg	1.00	1.00	1.00	200 000

Tabla 11: K-NN: métricas.

2. **Arbol de decisión.** Se buscó la mejor configuración de hiperparámetros en relación con el desempeño de los modelos, el rango de búsqueda para este escenario, fue el mismo que para el anterior, es decir, los mismos establecidos en la Tabla 2. La mejor configuración para cada dataset fue la siguiente:

Tamaño (muestras)	max_depth	min_samples_leaf	min_samples_split
100	None	1	2
1 000	None	1	2
10 000	15	1	2
100 000	None	1	2
1 000 000	20	1	2

Tabla 12: Mejores hiperparámetros Arbol de decisión SC2.

Las métricas de desempeño correspondientes se muestran a continuación:

Tamaño (muestras)	Línea	Precision	Recall	F1-score	Support
100	Clase 0	1.00	0.80	0.89	5
	Clase 1	0.50	0.40	0.44	5
	Clase 2	0.62	1.00	0.77	5
	Clase 3	1.00	0.80	0.89	5
	Accuracy	—	—	0.75	20
	Macro avg	0.78	0.75	0.75	20
	Weighted avg	0.78	0.75	0.75	20
1 000	Clase 0	0.96	0.96	0.96	50
	Clase 1	0.95	0.78	0.86	50
	Clase 2	0.75	0.98	0.85	50
	Clase 3	0.98	0.86	0.91	50
	Accuracy	—	—	0.90	200
	Macro avg	0.91	0.89	0.90	200
	Weighted avg	0.91	0.90	0.90	200
10 000	Clase 0	0.98	0.98	0.98	500
	Clase 1	0.96	0.96	0.96	500
	Clase 2	0.95	0.94	0.95	500
	Clase 3	0.97	0.97	0.97	500
	Accuracy	—	—	0.96	2 000
	Macro avg	0.96	0.96	0.96	2 000
	Weighted avg	0.96	0.96	0.96	2 000
100 000	Clase 0	0.99	0.99	0.99	5 000
	Clase 1	0.99	0.99	0.99	5 000
	Clase 2	0.98	0.98	0.98	5 000
	Clase 3	0.99	0.99	0.99	5 000
	Accuracy	—	—	0.99	20 000
	Macro avg	0.99	0.99	0.99	20 000
	Weighted avg	0.99	0.99	0.99	20 000
1 000 000	Clase 0	1.00	1.00	1.00	50 000
	Clase 1	0.99	1.00	1.00	50 000
	Clase 2	0.99	0.99	0.99	50 000
	Clase 3	1.00	1.00	1.00	50 000
	Accuracy	—	—	1.00	200 000
	Macro avg	1.00	1.00	1.00	200 000
	Weighted avg	1.00	1.00	1.00	200 000

Tabla 13: Reportes de clasificación Árbol de decisión SC2.

3. **SVM.** Buscando la mejor configuración de hiperparámetros en relación con el desempeño de los modelos, se optó por probar con las siguientes posibilidades:

Parámetro	Descripción	Valores probados
C	Parámetro de regularización (controla el castigo por errores).	{0.1, 1, 10}
kernel	Tipo de núcleo utilizado por SVM.	{linear, rbf}
gamma	Coefficiente del kernel (aplica a rbf; se ignora en linear).	{scale, auto}

Tabla 14: Búsqueda de hiperparámetros para SVM SC2.

Se tuvieron las siguientes mejores configuraciones para cada dataset:

Tamaño (muestras)	C	gamma	kernel
100	10	scale	rbf
1 000	10	auto	rbf
10 000	10	scale	rbf

Tabla 15: Mejores hiperparámetros SVM SC2.

Las métricas de desempeño correspondientes se muestran a continuación:

Clase	Precision	Recall	F1-Score	Support
(a) 100 muestras				
0	1.00	0.80	0.89	5
1	0.57	0.80	0.67	5
2	0.50	0.60	0.55	5
3	1.00	0.60	0.75	5
Accuracy			0.70	20
Macro avg	0.77	0.70	0.71	20
Weighted avg	0.77	0.70	0.71	20
Tiempo (s): 0.26				
(b) 1 000 muestras				
0	0.98	0.98	0.98	50
1	0.96	0.90	0.93	50
2	0.92	0.98	0.95	50
3	1.00	1.00	1.00	50
Accuracy			0.96	200
Macro avg	0.97	0.96	0.96	200
Weighted avg	0.97	0.96	0.96	200
Tiempo (s): 1.48				
(c) 10 000 muestras				
0	1.00	0.99	0.99	500
1	0.99	1.00	0.99	500
2	0.99	0.98	0.99	500
3	0.98	0.99	0.99	500
Accuracy			0.99	2 000

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
Macro avg	0.99	0.99	0.99	2 000
Weighted avg	0.99	0.99	0.99	2 000
Tiempo (s): —				

Tabla 16: Reportes de clasificación SVM SC2.

Nota: No fue posible ejecutar el código para la búsqueda de los mejores hiperparámetros ni para la implementación de los modelos en los datasets de tamaño 10^5 y 10^6 . En Colab, el tiempo de ejecución superó una hora sin finalizar el proceso, por lo que no se obtuvieron los hiperparámetros óptimos ni los resultados correspondientes para estos tamaños.

4. **MLP.** Buscando la mejor configuración de hiperparámetros en relación con el desempeño de los modelos, se optó por probar con las siguientes posibilidades:

Parámetro	Descripción	Valores de búsqueda
<code>hidden_layer_sizes</code>	Tamaño(s) de la(s) capa(s) oculta(s)	(50,), (100,), (50, 50)
<code>activation</code>	Función de activación en capas ocultas	<code>tanh</code> , <code>relu</code>
<code>solver</code>	Optimizador para los pesos	<code>adam</code>
<code>alpha</code>	Penalización L2 (regularización)	0.0001, 0.001
<code>learning_rate_init</code>	Tasa de aprendizaje inicial	0.001, 0.01
<code>max_iter</code>	Iteraciones máximas de entrenamiento	200, 500

Tabla 17: Búsqueda hiperparámetros MLP SC2

Solo se usó un solo optimizador de pesos, conforme lo sugirió la IA de Colab, y se hallaron las siguientes mejores configuraciones:

Tamaño (muestras)	<code>hidden_layer_sizes</code>	<code>activation</code>	<code>solver</code>	<code>alpha</code>	<code>learning_rate_init</code>	<code>max_iter</code>
100	(100,)	<code>relu</code>	<code>adam</code>	0.0001	0.01	500
1 000	(50, 50)	<code>relu</code>	<code>adam</code>	0.001	0.01	200
10 000	(50, 50)	<code>tanh</code>	<code>adam</code>	0.0001	0.001	500

Tabla 18: Mejores hiperparámetros encontrados para MLP SC2.

Se generó el siguiente reporte de clasificación:

Clase	Precision	Recall	F1-Score	Support
(a) 100 muestras				
0	0.83	1.00	0.91	5
1	0.60	0.60	0.60	5
2	0.60	0.60	0.60	5
3	1.00	0.80	0.89	5
Accuracy			0.75	20
Macro avg	0.76	0.75	0.75	20
Weighted avg	0.76	0.75	0.75	20

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
(b) 1 000 muestras				
0	1.00	0.94	0.97	50
1	0.92	0.96	0.94	50
2	0.96	0.90	0.93	50
3	0.93	1.00	0.96	50
Accuracy			0.95	200
Macro avg	0.95	0.95	0.95	200
Weighted avg	0.95	0.95	0.95	200
(c) 10 000 muestras				
0	1.00	0.99	1.00	500
1	0.99	0.99	0.99	500
2	0.99	0.99	0.99	500
3	1.00	0.99	0.99	500
Accuracy			0.99	2 000
Macro avg	0.99	0.99	0.99	2 000
Weighted avg	0.99	0.99	0.99	2 000

Tabla 19: Reportes de clasificación MLP SC2.

Nota: Al igual que con el clasificador SVM, no fue posible terminar la ejecución del código para la búsqueda de los mejores hiperparámetros ni para la implementación de los modelos en los datasets de tamaño 10^5 y 10^6 . En Colab, el tiempo de ejecución se superó el tiempo de una hora y media sin finalizar el proceso, por lo que no se obtuvieron los hiperparámetros óptimos ni los reportes de clasificación correspondientes para estos tamaños. Incluso, el compilador de Colab parece bloquearse conforme más le toma realizar una interpretación.

5. Análisis de resultados.

En los *Quartiles Gaussian* de cuatro clases, el tamaño del conjunto de datos marca la diferencia: con muy pocos ejemplos, los modelos son inestables pero al pasar a 1,000 muestras ya se observa una mejora clara y, con 10,000 en adelante, las fronteras quedan bien definidas y todos los clasificadores aciertan casi siempre. Esto sugiere que las clases son separables pero requieren densidad de puntos; con más datos se “suavizan” los límites. En escalabilidad, el modelo k-NN se entrena rápido pero su predicción se encarece con muchos datos; el Árbol ofrece interpretabilidad; y SVM/MLP rinden muy alto aunque su costo computacional crece muchísimo. En síntesis, con pocos datos conviene regularizar y validar con cuidado, con muchos datos, cualquiera funciona bien y la elección debería guiarse por el costo de inferencia, interpretabilidad y el gasto computacional.

Adicionalmente, la Figura 4 muestra el desempeño de los modelos ejecutados:




Figura 4: Desempeño modelos SC2.

5. Escenario 3: grandes datasets vs pequeños datasets

En este escenario, se indica generar un dataset binario y construir a partir de el dos nuevos datasets, cada uno con una tasa de corrupción específica. Las tasas de corrupción definidas son las siguientes: 10 %, y 30 %. De tal forma, que en total se tienen 3 datasets, el original y los dos corrompidos de acuerdo con su respectiva tasa de corrupción. El **Assignment #4** no definió el tamaño de los datasets, así que se optó por conformarlos con 700 registros cada uno. Por otra parte, el **Assignment #4** si define el tipo de datos que deben tener los datasets, en este caso, de tipo **Moon**. En este escenario tampoco se va a optar por generar un desbalance entre las clases, y tal como se hizo en los anteriores, se dividirá cada dataset en conjunto de entrenamiento, validación y prueba, así como la búsqueda de los mejores hiperparámetros para los mismos modelos de clasificación que se han venido ejecutando. También se tuvo en cuenta en la generación de estos datasets, mantener la proporción de clases del dataset original.

1. **k-NN**. Probando con un rango de 1 a 30 vecinos (al igual que en los anteriores escenarios) para cada uno de los datasets conformados, se consiguieron las siguientes mejores configuraciones:

Dataset	n_neighbors
clean	1
noisy_10	7
noisy_30	25

Tabla 20: Mejores hiperparámetros KNN SC3.

Respecto al desempeño obtenido en cada uno de los modelos se tienen los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) clean				
0	1.00	1.00	1.00	70
1	1.00	1.00	1.00	70
Accuracy			1.00	140
Macro avg	1.00	1.00	1.00	140
Weighted avg	1.00	1.00	1.00	140
(b) noisy_10				
0	0.92	0.86	0.89	71
1	0.86	0.93	0.90	69
Accuracy			0.89	140
Macro avg	0.89	0.89	0.89	140
Weighted avg	0.89	0.89	0.89	140
(c) noisy_30				
0	0.69	0.70	0.69	69
1	0.70	0.69	0.70	71
Accuracy			0.69	140
Macro avg	0.69	0.69	0.69	140
Weighted avg	0.69	0.69	0.69	140

Tabla 21: Reportes de clasificación k-NN SC3.

2. **Arbol de decisión.** Se buscó la mejor configuración de hiperparámetros en el mismo marco de los anteriores escenarios (ver Tabla 2). Con base en esta búsqueda se obtuvieron las siguientes mejores configuraciones de hiperparámetros para cada dataset:

Dataset	max_depth	min_samples_leaf	min_samples_split
clean	None	1	2
noisy_10	5	2	2
noisy_30	5	4	2

Tabla 22: Mejores hiperparámetros Árbol de decisión SC3.

Respecto al desempeño obtenido en cada uno de los modelos se tienen los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) clean				
0	1.00	1.00	1.00	70
1	1.00	1.00	1.00	70
Accuracy			1.00	140
Macro avg	1.00	1.00	1.00	140
Weighted avg	1.00	1.00	1.00	140
(b) noisy_10				
0	0.90	0.86	0.88	71
1	0.86	0.90	0.88	69
Accuracy			0.88	140
Macro avg	0.88	0.88	0.88	140
Weighted avg	0.88	0.88	0.88	140
(c) noisy_30				
0	0.63	0.59	0.61	69
1	0.63	0.66	0.64	71
Accuracy			0.63	140
Macro avg	0.63	0.63	0.63	140
Weighted avg	0.63	0.63	0.63	140

Tabla 23: Reportes de clasificación Arbol de decisión SC3.

3. **SVM.** Para este clasificador se buscó la mejor configuración de hiperparámetros probando los mismos valores del anterior escenario (ver Tabla 14). Los mejores hiperparámetros encontrados para cada dataset, fueron los siguientes:

Dataset	C	gamma	kernel
clean	1	scale	rbf
noisy_10	1	scale	rbf
noisy_30	1	scale	rbf

Tabla 24: Mejores hiperparámetros encontrados para SVM SC3.

Con los mejores hiperparámetros encontrados, se obtuvieron los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) clean				
0	1.00	1.00	1.00	70
1	1.00	1.00	1.00	70
Accuracy			1.00	140
Macro avg	1.00	1.00	1.00	140
Weighted avg	1.00	1.00	1.00	140
(b) noisy_10				
0	0.92	0.86	0.89	71

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
1	0.86	0.93	0.90	69
Accuracy			0.89	140
Macro avg	0.89	0.89	0.89	140
Weighted avg	0.89	0.89	0.89	140
(c) noisy_30				
0	0.69	0.70	0.69	69
1	0.70	0.69	0.70	71
Accuracy			0.69	140
Macro avg	0.69	0.69	0.69	140
Weighted avg	0.69	0.69	0.69	140

Tabla 25: Reportes de clasificación SVM SC3.

4. **MLP.** Para este clasificador se buscó la mejor configuración de hiperparámetros probando con los siguientes valores:

Parámetro	Descripción	Valores de búsqueda
hidden_layer_sizes	Tamaño(s) de la(s) capa(s) oculta(s)	(50,), (100,), (50, 50)
activation	Función de activación en capas ocultas	tanh , relu
solver	Optimizador para los pesos	adam
alpha	Penalización L2 (regularización)	0.0001, 0.001
learning_rate_init	Tasa de aprendizaje inicial	0.001, 0.01

Tabla 26: Espacio de búsqueda de hiperparámetros para `MLPClassifier`.

Solo se usó un solo optimizador de pesos, conforme lo sugirió la IA de Colab. Con base en esta búsqueda se obtuvieron las siguientes mejores configuraciones de hiperparámetros para cada dataset:

Dataset	hidden_layer_sizes	activation	solver	alpha	learning_rate_init	max_iter
clean	(50,)	tanh	adam	0.0001	0.01	200
noisy_10	(50, 50)	tanh	adam	0.001	0.01	500
noisy_30	(50, 50)	relu	adam	0.001	0.01	200

Tabla 27: Mejores hiperparámetros encontrados para MLP SC3.

Con la configuraciones de hiperparámetros encontradas, se obtuvieron los siguientes resultados:

Clase	Precision	Recall	F1-Score	Support
(a) clean				
0	0.93	0.89	0.91	70
1	0.89	0.93	0.91	70

Continúa en la siguiente página

Clase	Precision	Recall	F1-Score	Support
Accuracy			0.91	140
Macro avg	0.91	0.91	0.91	140
Weighted avg	0.91	0.91	0.91	140
(b) noisy_10				
0	0.81	0.79	0.80	71
1	0.79	0.81	0.80	69
Accuracy			0.8	140
Macro avg	0.80	0.80	0.80	140
Weighted avg	0.80	0.80	0.80	140
(c) noisy_30				
0	0.70	0.67	0.68	69
1	0.69	0.72	0.70	71
Accuracy			0.69	140
Macro avg	0.69	0.69	0.69	140
Weighted avg	0.69	0.69	0.69	140

Tabla 28: Reportes de clasificación del MLP SC3.

5. Análisis de resultados.

En este escenario, el aspecto clave a analizar fue el ruido introducido en las etiquetas de etiquetas: con datos limpios, los cuatro modelos demarcan una frontera nítida y aciertan prácticamente todo, con 10 % de ruido el desempeño baja de forma moderada y los mejores ajustes “se suavizan”, con 30 % de ruido la caída es notoria y los modelos convergen a resultados medios porque la señal contiene contradicciones. En estos casos ayudan más la regularización y márgenes amplios (SVM/MLP), el suavizado en k-NN y el control de profundidad del Árbol.

La Figura 5 muestra el desempeño de los modelos ejecutados.




Figura 5: Desempeño modelos SC3.

6. Discusión de nuestro reciente trabajo sobre LLM

Elegí el artículo [New Kid in the Classroom: Exploring Student Perceptions of AI Coding Assistants](#) con base en que soy un desarrollador de software que recientemente empezó a desarrollar, y por lo tanto, no me he formado en esta área sin la existencia y asistencia de la Inteligencia Artificial (IA), me gustaría indagar como se puede hacer uso de la IA de una manera apropiada sin incurrir en una dependencia de la IA, o en no aprender apropiadamente los conceptos. A continuación, dejo mis impresiones sobre lo que considero podrían ser nuevas propuestas de investigación con base en la lectura del artículo mencionado.

1. **Análisis del aprendizaje con IA.** *Hipótesis:* la IA acelera el aprendizaje inicial, pero puede reducir la verdadera captura y retención del conocimiento cuando se retira.
2. **Como pensar con la IA.** *Hipótesis:* guiar el uso de IA hacia la explicación, la crítica y las preguntas, mejora la comprensión y autonomía frente a la simple solicitud de tareas.