

Agrupamiento jerárquico

Haessler Joan Ortiz Moncada

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Curso: Big Data

5 de octubre de 2025

1. Introducción

Este documento presenta el desarrollo de los ejercicios planteados en el **Taller_6** del curso de Big Data, documentando los hallazgos y análisis correspondientes. Este taller se centra principalmente en el abordaje de dos *datasets*: uno proporcionado por el profesor de la clase, denominado `data_clusters.mat`, y otro descargado de [Anuran Calls](#). A partir de estos conjuntos de datos se busca implementar y practicar metodologías de clasificación no supervisada, específicamente agrupamiento jerárquico.

2. Metodología

En cuanto al orden, el trabajo se desarrolla conforme a lo establecido en el **Taller_6**. Respecto a la forma, la implementación de los modelos, la preparación de los datos y la visualización de los resultados se llevan a cabo mediante un archivo de **Jupyter Notebook** desarrollado en Colab. Cabe aclarar que la Inteligencia Artificial (IA) Gemini asistió en la generación del código requerido. Por último, el código producido, los datos implementados y el informe generado, pueden consultarse en la carpeta `taller_6` del repositorio [bigdata_repositorio](#) de GitHub.

3. Desarrollo

El **Taller_6** consta de dos ítems principales: el primero requiere implementar el método de agrupamiento jerárquico en el dataset `data_clusters.mat` para definir el número óptimo de *clusters*, lo cual debe complementarse con la implementación de dendrogramas y la evaluación del rendimiento del modelo mediante el índice de *Silhouette* y el análisis de la Suma de Errores Cuadráticos (**SSE**, por sus siglas en inglés); mientras que el segundo ítem también requiere la aplicación del agrupamiento jerárquico para entrenar un modelo con el dataset **Anuran Calls**, una base de datos multiclase de sonidos de ranas, donde el objetivo es agrupar (enfoque no supervisado) o clasificar (enfoque semi-supervisado), según corresponda, las características `familia` y `género`.

3.1. Agrupamiento jerárquico con `data_clusters.mat`

Teniendo el dataset `data_clusters.mat`, se etiquetan sus dos columnas o características como **A** y **B**; se verifica que su tamaño es 135×2 , que ambas variables son de tipo `float` y que el conjunto no presenta valores nulos. Con el fin de facilitar su manipulación en el contexto de `Python`, se decide transformarlo a un archivo `.csv`. Como métodos para generar los dendrogramas se decidió emplear tres esquemas de enlace: enlace simple, enlace de centroide y enlace completo. Estos permiten contrastar cómo varía la estructura jerárquica según el criterio de agrupación (distancia mínima entre pares, distancia al centroide y distancia máxima entre pares, respectivamente) y se ilustran en la Figura 1. La distancia entre puntos se calcula mediante la métrica euclidiana.




Figura 1: Dendrogramas con diferentes métodos de enlace.

En los tres dendrogramas se notan comportamientos distintos: con *enlace simple* los datos se van “pegando” de a poquitos y forman cadenas largas, por lo que la separación entre grupos no queda muy clara; con *enlace centroide* los grupos aparecen más equilibrados y es fácil imaginar tres conjuntos principales; con *enlace completo* la separación es la más nítida, porque prioriza que cada grupo quede bien compacto y distinto de los demás. En resumen, para este conjunto de datos conviene **a priori** quedarse con *enlace completo* y, como alternativa cercana, *centroide*; en ambos casos un corte natural del árbol sugiere trabajar con dos o tres grupos.

Como forma de cuantificar la calidad del agrupamiento, se decide calcular el índice de *Silhouette* y la *SSE* para cada método de enlace, variando el número de *clusters* entre 2 y 10. Realmente no se tiene un criterio estricto del porqué se define ese rango, pero se asume que es un intervalo razonable para este conjunto de datos. Tanto para *Silhouette* y *SSE* se implementaron estrategias para detener su cálculo en caso de que empeorara el rendimiento del coeficiente y el segundo entrara en una meseta, respectivamente. Para esta labor si se implementó una estandarización previa de los datos. Los resultados se presentan en las Figuras 2 to 4.




Figura 2: Silhouette y SSE para enlace simple.




Figura 3: Silhouette y SSE para enlace de centroide.




Figura 4: Silhouette y SSE para enlace completo.

A partir de los gráficos recién mostrados, se observa que los tres métodos (enlace simple, enlace de centroide y enlace completo) producen resultados prácticamente indistinguibles: en todos los casos, la mejor elección para la cantidad de grupos es $k = 5$. Esto sugiere que, para el conjunto de datos evaluado, no hay una ventaja apreciable en preferir uno u otro criterio de enlace.

Nota: el Taller_6 requería que a partir de los dendogramas se compararan las agrupaciones que generó cada tipo de enlace, y que a partir de ello se realizará un histograma

que permitiera evaluar aquellas agrupaciones comunes, sin embargo, resulta complejo visualizar esta tarea. Tal vez una propuesta similar, sería la de evaluar cuántas veces un par de datos queda en el mismo clúster, sin llegar a identificar cuáles son los datos que se están agrupando.

3.2. Agrupamiento jerárquico con Anuran Calls

El segundo ítem de `Taller_6` utiliza el conjunto de datos `Anuran Calls`, que contiene grabaciones de llamadas de ranas y características acústicas extraídas. El objetivo es agrupar las observaciones según `familia` y `género`. Para el análisis no supervisado se emplean únicamente las características numéricas, descartando las variables categóricas y la última característica numérica, ya que solo identifica la grabación y no aporta información al agrupamiento. En el enfoque supervisado se genera una etiqueta compuesta que combina `familia` y `género`, de modo que cada combinación única constituye una clase. Durante la preparación de los datos se verifica la ausencia de valores nulos y no se aplica estandarización, puesto que todas las características numéricas están en la misma escala (entre -1 y 1). El conjunto de datos original tiene un tamaño de 7195×22 y no posee valores nulos.

3.2.1. Análisis No supervisado

Para el análisis no supervisado, se eligió la técnica *k-medoids* para la identificación de protogrupos, con la intención de no realizar el agrupamiento jerárquico directamente sobre el conjunto de datos completo, dada su considerable dimensión, con esto se reduce el tiempo y complejidad del computo. Se probó con distintos tamaños (g) para definir los protogrupos, eligiendo finalmente $g = 80$ como el valor con mejor rendimiento según el índice de *Silhouette*. Este tamaño es la cantidad de protogrupos que se utilizarán como entrada para el agrupamiento jerárquico. Para los tamaños de los protogrupos se evaluaron los valores $g = \{80, 100, 120, 150\}$, como regla deben ser de un tamaño mucho mayor al que probablemente se elija para k en el agrupamiento jerárquico. La Figura 5 muestra el desempeño del índice de *Silhouette* para diferentes valores de g .




Figura 5: Silhouette para diferentes tamaños de protogrupos g .

Posteriormente, se aplicaron los métodos de (*single linkage*) y (*complete linkage*) para generar los respectivos dendrogramas. La Figura 6 muestra los dendrogramas generados.




Figura 6: Dendrogramas para Anuran Calls.

Finalmente, se evaluaron diferentes valores de k (número de grupos) en el rango de 2 a 12, calculando el índice de *Silhouette* para cada configuración (valor de k y tipo de enlace). Los resultados se presentan en la Figura 7.




Figura 7: Silhouette para diferentes k y métodos de enlace.

Con base en los resultados obtenidos, se observa que el mejor rendimiento del índice de *Silhouette* se alcanza con $k = 2$, utilizando el método de *enlace completo*. Este hallazgo sugiere que, para el conjunto de datos **Anuran Calls**, la configuración óptima para el agrupamiento jerárquico es con dos grupos y empleando el criterio de enlace completo. No obstante, el coeficiente de *Silhouette* obtenido es relativamente bajo, lo que indica que los grupos formados no están muy bien definidos y que podría haber una considerable superposición entre ellos. Es posible que muchas de las características del conjunto de

datos no sean relevantes para la tarea de agrupamiento, lo que dificulta la formación de grupos claros y distintos.

3.2.2. Análisis Semi-supervisado

Se fijó $g = 80$ protogrupos con K-medoids (reusando lo definido en el ejercicio no supervisado). Sobre los medoides resultantes se construyó un agrupamiento jerárquico con dos tipos de enlace: *single* y *complete*. Para cada método se evaluaron cortes del dendrograma con $K \in \{2, \dots, 12\}$. Se generaron los dendrogramas y, para cada (método, K), se calculó el **índice de Silhouette** en el conjunto de entrenamiento ampliado (5 % etiquetado + 85 % no etiquetado), sin usar etiquetas. El mejor modelo jerárquico se determinó por el **índice de Silhouette**: entre todas las combinaciones (método, K) se eligió aquella con mayor **Silhouette**. Para hacer la tarea de clasificación, cada clúster final se rotuló con la etiqueta **Family|Genus** que resultó mayoritaria entre las observaciones del 5 % etiquetado que cayeron en ese clúster. Usando exclusivamente el 5 % etiquetado, se realizó validación cruzada para estimar el desempeño en clasificación del modelo seleccionado (método y K fijos por Silhouette). Los resultados de la métrica se presentan en la Figura 8.




Figura 8: F1 score para cada método de enlace.

Dado que el mejor método de enlace fue *complete linkage*, se construyó el modelo final replicando el procedimiento usado en la fase de selección, pero aplicado exclusivamente a este enlace. La Figura 9 presenta el dendrograma resultante.




Figura 9: Dendrograma enlace completo enfoque semisupervisado.

Con los clústeres definidos en el dendrograma y el valor óptimo del coeficiente de *Silhouette* encontrado para $k = 2$. Las etiquetas se asignaron por mayoría utilizando el subconjunto etiquetado 5 %. Posteriormente, el modelo se evaluó en el conjunto de prueba (10 %), obteniéndose la matriz de confusión mostrada en la Figura 10.




Figura 10: Matriz de confusión para $k = 2$ y enlace completo.

Con base en los resultados, el número óptimo de clústeres fue $k = 2$, por lo que el modelo jerárquico solo separa la muestra en dos grupos y no logra representar las ocho clases reales del problema. Además, su desempeño es bajo (exactitud y precisión reducidas). Entre las posibles causas para este bajo desempeño se encuentran:

- Ausencia de un análisis de características que descarte colinealidad y variables ruidosas.
- Desbalance de clases. Es probable que la clase más frecuente esté sesgando la agrupación y la clasificación.
- Limitaciones del enfoque jerárquico para este dominio específico.

4. Conclusiones

- En el caso del dataset `data_clusters.mat`, los diferentes métodos de enlace produjeron resultados similares, sugiriendo que el conjunto de datos tiene una estructura clara que puede ser capturada con varios enfoques.
- Para mejorar los resultados futuros, se recomienda realizar un análisis exhaustivo de las características para identificar y eliminar variables redundantes o irrelevantes, así como considerar técnicas adicionales para manejar el desbalance de clases.
- No está del todo claro cómo definir el rango de búsqueda de k en el agrupamiento jerárquico ni en otras técnicas no supervisadas vistas en clase. No existe un criterio estricto que justifique un rango específico; la literatura sugiere una relación entre el tamaño del conjunto de datos y dicho rango, pero no constituye una norma, sino pautas heurísticas derivadas de la experimentación.
- La IA tiende a generar código generalista, a menudo no óptimo para casos específicos e, incluso, redundante o excesivo. Funciona mejor cuando se le formulan *prompts* breves y precisos, enmarcados en un contexto previo y claro del problema.