

Proyecto Final Big Data: Módulo No Supervisado

Haessler Joan Ortiz Moncada

Universidad Distrital Francisco José de Caldas

Facultad de Ingeniería

Curso: Big Data

19 de octubre de 2025

1. Introducción

Este documento presenta el desarrollo de los ejercicios del `Taller_7` del curso de Big Data, documentando los hallazgos y los análisis correspondientes. El taller se centra en el archivo `dato_taller.mat` proporcionado por el docente, que contiene tres conjuntos de datos: (i) `x_prueba`, una matriz de 1000×20 ; (ii) `x_entena`, otra matriz de 1000×20 ; y (iii) `y_prueba`, un vector de etiquetas de tamaño 1000×1 asociado a `x_entena`. El objetivo es generar un vector de etiquetas para `x_prueba` utilizando la información de `x_entena` y su correspondiente vector de etiquetas `y_prueba`, mediante las técnicas de agrupamiento no supervisado vistas en clase.

2. Metodología

Con la información proporcionada, se prepararon los datos en `MATLAB` —por tratarse de un archivo nativo— extrayendo la información de `dato_taller.mat` y convirtiendo cada conjunto al formato `CSV`, que luego se cargó en un `Jupyter Notebook` ejecutado en Google Colab; previo a aplicar los modelos, se verificó la naturaleza de los datos y el dominio de las características, y se realizó una selección de variables con el fin de mejorar el desempeño de los algoritmos; posteriormente, se implementaron y compararon varios modelos de agrupamiento no supervisado vistos en clase —incluyendo k -means, agrupamiento jerárquico, mapas autorganizados (SOM. por sus siglas en inglés) y DBSCAN— evaluando distintas configuraciones (hiperparámetros) para seleccionar las que ofrecieran mejores métricas de desempeño; el trabajo sigue el orden establecido en el `Taller_7` y contó con la asistencia de la IA Gemini en parte del código; finalmente, el código, los datos utilizados y el informe pueden consultarse en la carpeta `taller_7` del repositorio de GitHub [bigdata_repositorio](#).

3. Desarrollo

3.1. Descripción de los datos

El archivo `dato_taller.mat` es un archivo de MATLAB de tipo *struct* que contiene tres campos: `x_prueba`, `x_entena` y `y_prueba`. El primero es una matriz de tamaño 10000×20 ; el segundo, otra matriz de tamaño 1000×20 ; y el tercero, un vector de tamaño 1000×1 que contiene las etiquetas asociadas a las filas de `x_entena`. En cuanto a los datos, no se proporciona información adicional sobre su origen, naturaleza o significado, ni sobre los nombres de las características. Respecto al dominio de las características, se observa que los valores de las columnas de `x_prueba` y `x_entena` se encuentran estandarizados y, como es lógico, son datos de tipo *double* (precisión doble). El conjunto de datos `x_entena` fue renombrado a `x_entrena` para reflejar mejor su propósito en el contexto del taller. En cuanto al vector de etiquetas `y_prueba`, se observó que tiene una clasificación binaria, con valores de 1 y -1, y que está un poco desbalanceado (ver figura 1), ya que 531 de las etiquetas son 1 y el restante son -1, es decir, 469. Por otra parte, ningún conjunto de datos contiene valores o registros nulos o faltantes.




Figura 1: Distribución de clases en `y_prueba`.

3.2. Preparación de los datos

Antes de aplicar los modelos de agrupamiento, se unificaron los conjuntos `x_entrena` y `x_prueba` en un único conjunto denominado `x_total`, con el fin de aprovechar toda la información disponible y facilitar la evaluación del desempeño del modelo propuesto. La unificación se realizó concatenando verticalmente ambas matrices, obteniéndose una matriz de tamaño 11000×20 . Se asumió que las características de ambos conjuntos corresponden a las mismas variables. Dado que las características no estaban nombradas, se asignaron identificadores genéricos a las columnas de `x_total`, desde `col1` hasta `col20`;

para las etiquetas, el campo se denominó `clase`. Como paso previo a la selección de características, se llevó a cabo un filtrado de valores atípicos mediante el rango intercuartílico (*IQR*). Se empleó un umbral de $1,5 \times IQR$ para definir los límites superior e inferior y se eliminó todo registro cuyo valor en cualquiera de sus características quedara por fuera de dichos límites. Con este procedimiento se suprimieron 1218 registros, quedando 9782 observaciones en un nuevo conjunto denominado `x_total_filtrado`; el conjunto `x_total` se conservó sin modificaciones. Este filtrado busca facilitar el agrupamiento en métodos que no modelan explícitamente *outliers*, como *k*-means y el agrupamiento jerárquico. Con esta reducción de muestras se pierde alrededor del 12 % de la información original.

Otro aspecto analizado fue la distribución de los valores de las características (véase figura 2), con el fin de identificar posibles sesgos o la necesidad de aplicar transformaciones. De este examen se concluyó que no eran necesarias transformaciones adicionales, pues las variables presentan distribuciones aproximadamente simétricas respecto de su media y una curtosis "normal".




Figura 2: Distribución de las características.

Al observar el gráfico anterior se podría teorizar que el conjunto de datos de estudio, corresponde a uno de naturaleza sintética y que guarda relación con alguna figura geométrica.

3.3. Selección de características

Dado que no se proporciona información sobre el significado de las características, se optó por utilizar un análisis de correlación (correlación de Pearson) para identificar posibles relaciones lineales entre las características, además, también se implementó un análisis de componentes principales (*PCA*, por sus sigla en inglés) para explorar la reducción de la dimensionalidad de los datos originales.

Se calculó la matriz de correlación para las 20 características de `x_total_filtrado` y se visualizó mediante un mapa de calor (ver figura 3). Se observó que algunas todas las características tienen una correlación baja entre sí (valores cercanos a 0), lo que sugiere (*a priori*) que no hay redundancia significativa entre ellas. Por lo tanto, el análisis de correlación no indicó la necesidad de eliminar ninguna característica.




Figura 3: Matriz de correlación entre las características de `x_total`.

Se aplicó *PCA* a `x_total` para evaluar la reducción de dimensionalidad. Se observó que las dos primeras componentes principales explican aproximadamente el 25 % de la varianza total (esto es, cerca de 12,5 % cada una; véase figura 4), mientras que las restantes presentan aportes pequeños y similares (alrededor de $\sim 4\%$ cada una). Para este *PCA* se consideró un umbral de varianza explicada del 95 % para determinar el número óptimo de componentes a retener; se encontró que se requieren al menos 19 componentes para alcanzar dicho umbral, lo cual indica que la mayoría de las características originales contribuyen de forma significativa a la varianza total. En consecuencia, se decidió conservar todas las características originales para el análisis de agrupamiento, puesto que reducir a dos dimensiones implicaría una pérdida sustantiva de información.




Figura 4: Varianza explicada por cada *PCA*.


La tabla 1 muestra la varianza explicada y la varianza acumulada para cada uno de los componentes principales generados.

Componente	Varianza explicada	Varianza acumulada
1	12.82 %	12.82 %
2	12.32 %	25.14 %
3	4.51 %	29.66 %
4	4.38 %	34.04 %
5	4.36 %	38.40 %
6	4.32 %	42.72 %
7	4.26 %	46.98 %
8	4.25 %	51.23 %
9	4.24 %	55.47 %
10	4.21 %	59.68 %
11	4.15 %	63.83 %
12	4.15 %	67.97 %
13	4.13 %	72.10 %
14	4.11 %	76.21 %
15	4.06 %	80.26 %
16	4.03 %	84.30 %
17	4.00 %	88.29 %
18	3.97 %	92.26 %
19	3.88 %	96.14 %


Tabla 1: *PCA*: varianza explicada por componente y acumulada.

3.4. k-means

Se entrenó un modelo de k -means para distintos números de grupos, probando $k \in [2, 20]$. Para cada k , los centroides iniciales se eligieron con la técnica k -means++ y se realizaron 10 reinicios independientes para obtener la mejor solución. En cada reinicio, el *algoritmo de Lloyd* iteró hasta 100 pasos como máximo o hasta que la función objetivo (inercia) dejara de mejorar más de 10^{-4} entre iteraciones consecutivas. Se registró la mejor inercia final por cada k para construir el gráfico del codo (número de clusters vs. inercia) y, adicionalmente, se generó un gráfico *Silhouette* con el fin de comparar la calidad de la separación entre grupos y elegir el k que mejor organiza los datos. La figura 5 muestra el resultado de este procedimiento.



(a) Gráfico del codo.



(b) Gráfico de *silhouette*.

Figura 5: Implementación de k -means.

De los resultados se concluye que la mejor relación entre reducción de inercia y número de grupos (sin caer en un exceso de grupos), según el gráfico del codo, se da aproximadamente para $k = 5$. Sin embargo, al observar el gráfico de *silhouette*, aunque el mejor promedio del coeficiente (más cercano a 1) es cuando $k = 2$, se aprecian valores de *silhouette* muy bajos, lo que indica una separación poco nítida entre grupos. En conjunto, estos hallazgos sugieren que k -means no resulta un método adecuado de agrupamiento para este conjunto de datos.

3.5. Agrupamiento jerárquico

Para reducir el costo del agrupamiento jerárquico, primero se condensó el conjunto estandarizado (9782×20) en protoclústeres (m) mediante *Mini-Batch k-means*, que actualiza centroides con mini-lotes (subconjuntos de 1024–2048 filas por iteración) para acelerar el cálculo y disminuir el uso de memoria. Se probó un rango de tamaños $m \in \{400, 600, 800, 1000, 1200\}$ con configuración reproducible para replicar los resultados, reinicios múltiples (`n_init` = 10; varias inicializaciones y elección de la mejor por menor inercia/SSE) y un criterio de parada por tolerancia (`tol` = $1e-4$) dentro de un límite de iteraciones (`max_iter` $\approx$ 100). El criterio de parada detiene el algoritmo cuando la inercia deja de mejorar de forma apreciable entre iteraciones (la caída es menor a la tolerancia). El rango de m equilibra detalle y costo: con $n = 9782$, valores entre $\sim 4 \times 10^{-2}n$ y $\sim 1,2 \times 10^{-1}n$ (es decir, ≈ 400 –1200) mantienen el paso jerárquico en un coste $\mathcal{O}(m^2)$ manejable para los servidores de *Colab*, esto permite preservar resolución suficiente para el dendrograma y evitan tanto microgrupos (si m es muy alto) como protoclústeres excesivamente grandes (si m es muy bajo); además, dejan tamaños esperados por protoclúster de

$n/m \approx 8\text{--}25$ observaciones, adecuados para representar la estructura sin sobrefragmentar. La figura 6 muestra como se comportan los mejores *coeficiente de Silhouette* para cada uno de los m probados.






Figura 6: *Coeficiente de Silhouette* versus m .

Del gráfico anterior se observa que, con $m = 400$, se obtiene el mayor *coeficiente de silhouette*, aunque sin alcanzar valores altos, esto no resulta preocupante en esta etapa, pues se trata de un paso previo al agrupamiento jerárquico.


Con la anterior información, se tomaron los centroides de los protoclústeres ($m = 400$) para trabajar con un resumen del conjunto y así agilizar el cálculo. Con esos centroides se construyó el árbol jerárquico (dendrograma) probando los enlaces *ward*, *single*, *average* y *complete*. Luego, para cada método, se cortó el árbol en distintos números de grupos (k de 2 a 12) y esas etiquetas se propagaron a todas las filas originales (cada fila hereda la etiqueta del protoclúster al que pertenece). Con esas etiquetas completas se calculó el *coeficiente de Silhouette* para medir qué tan bien se separan los grupos, y se guardó el mejor valor por cada método. Finalmente, para cada método se generó un dendrograma simplificado (mostrando solo los últimos 100 grupos) que ilustra visualmente la partición seleccionada. Como dato curioso, los mejores valores de *Silhouette* fueron con $k = 2$, al igual que cuando se desarrolló el método de agrupamiento *k-means*. Los dendrogramas generados se muestran en la figura 7.




(a) Enlace *ward* con $k = 2$.



(b) Enlace *single* con $k = 2$.



(c) Enlace *average* con $k = 2$.



(d) Enlace *complete* con $k = 2$.

Figura 7: Dendrogramas de los mejores agrupamientos encontrados.


A grandes rasgos, los cuatro dendrogramas se comportan como se esperaría según el criterio de enlace: el *single* muestra el típico “encadenamiento” (fusiones muy bajas y uno que otro salto al final), *complete* arma grupos más compactos y deja ver cortes razonables en $k \approx 3-5$; *average* queda en un punto medio, con separación moderada; y *ward* es el que luce más “limpio”, con saltos finales marcados y tamaños más equilibrados, sugiriendo cortes naturales en $k \approx 2-4$. Sin embargo, los correspondientes valores de *Silhouette*, arrojan valores bajos, lo que significa que la separación alcanzada no es buena, lo que permite concluir que los agrupamientos jerárquicos implementados no resultan adecuados para este conjunto de datos. La tabla 2 muestra las configuraciones para los agrupamientos con los mejores valores de *Silhouette*.

Método	k	<i>Silhouette</i>
Ward	2	0.0725
Single	2	0.0867
Average	2	0.1569
Complete	2	0.0700


Tabla 2: *Silhouette* por método de enlace.

3.6. DBSCAN


El método de agrupamiento *DBSCAN* requiere definir dos parámetros: el radio de vecindad (ε) y el número mínimo de vecinos (`min_samples`). Para estimar ε , se generó la curva de distancias al k -ésimo vecino (k -distance) probando `min_samples` $\in \{5, 8, 10, 12\}$, con el fin de ubicar el “codo” donde la distancia al k -ésimo vecino se dispara y, así, aproximar la escala a la que los datos se agrupan. La figura 8 muestra los resultados de esta búsqueda.




(a) Distancia al k -ésimo vecino (5).



(b) Distancia al k -ésimo vecino (8).



(c) Distancia al k -ésimo vecino (10).



(d) Distancia al k -ésimo vecino (12).

Figura 8: Gráficos para identificar ε .

Con base en el gráfico anterior, la distancia al k -ésimo vecino presenta un incremento marcado en el rango $[4.5 - 5.0]$. A partir de ello, se definió una rejilla para ε con paso de 0.1 y se mantuvieron inicialmente los valores de `min_samples` $\{5, 8, 12\}$ para evaluar *DBSCAN*. No obstante, el algoritmo no logró separar adecuadamente el conjunto: con distancia euclidiana y radios amplios, casi todos los puntos quedaron en un único grupo (lo que impide calcular *silhouette*); al reducir el radio y aumentar `min_samples`, el comportamiento fue similar. Con distancia de *coseno*, ajustando finamente ε , se obtuvieron dos grupos, pero con frontera difusa y un *silhouette* cercano a cero; al exigir mayor densidad, las métricas mejoraron a costa de etiquetar gran parte de los datos como “ruido”, lo cual resulta poco útil. En síntesis, en el espacio original de 20 variables *DBSCAN* no identifica “islas” de densidad bien definidas.

3.7. SOM: Mapas autorganizados

Utilizando el conjunto de datos `x_total_filtrado`, se entrenó un SOM con vecindad gaussiana en dos fases (ordenamiento global y ajuste fino) y se evaluó un barrido focalizado

de cinco retículas (18×18 , 22×22 , 26×26 , 30×30 y 34×34), seleccionando el modelo por *Quantization Error* (QE) (ver figura 9). Se obtuvo el mejor resultado con 30×30 neuronas ($QE \approx 4,072$), muy próximo a 32×32 ($QE \approx 4,075$) y 34×34 ($QE \approx 4,076$), lo que sugiere que un buen ajuste sucede en 30 ± 2 . Para interpretar la magnitud del *QE*, se contrastó con una referencia geométrica propia de datos estandarizados (*z-score*): en $d = 20$ dimensiones, la escala natural viene dada por $\sqrt{d} = \sqrt{20} \approx 4,47$; por tanto, el *QE* alcanzado está por debajo de dicha escala. La *U-Matrix* (ver figura 10) del 30×30 evidenció fronteras bien definidas y zonas internas homogéneas, coherentes con un mapa ordenado. En síntesis, se logró un equilibrio adecuado entre detalle y costo computacional, y el barrido reducido permitió acortar tiempos sin comprometer la calidad, contextualizando el *QE* con una métrica comprensible ($\sqrt{d}$ y $NQE = QE/\sqrt{d}$) en lugar de tomar su valor absoluto sin referencia.




Figura 9: *QE* versus tamaño de retícula.

Conclusión de la exploración actual. Como conclusión hasta el momento, los enfoques de agrupamiento tradicionales probados (*k-means*, *DBSCAN* y jerárquico) arrojaron valores bajos y/o inestables de *Silhouette*, lo que sugiere separaciones poco nítidas entre grupos. En contraste, el *SOM* mostró un desempeño más prometedor. En resumen, dentro del conjunto de pruebas no supervisadas realizadas hasta este punto, el *SOM* constituye la alternativa más sólida para estructurar el espacio de datos de estudio.

La siguiente labor del presente informe consiste en retomar los mejores modelos de esta exploración para evaluarlos no solo sobre el conjunto de datos utilizado hasta ahora, sino también sobre subespacios de componentes principales; allí se incorporarán métricas supervisadas (p.ej., desempeño de clasificación en el subconjunto etiquetado) con el fin de elegir el modelo que mejor agrupe y ofrezca mayor capacidad de clasificación.




Figura 10: *U-Matrix* mejor retícula según QE .

3.8. Análisis semisupervisado

En esta sección se retoman los mejores modelos de agrupamiento no supervisado probados previamente, con la intención de etiquetar los grupos formados a partir de las etiquetas conocidas de `y_prueba` y evaluar su desempeño en términos de clasificación. Se emplearon los conjuntos `x_total_filtrado` y `combined_x_PCA_df`; este último corresponde a la transformación por *PCA* de las 20 dimensiones originales. No obstante, para el desarrollo de los modelos se trabajó con 15 componentes principales (aprox. 80 % de varianza explicada), a fin de contrastar si *PCA* mejora el agrupamiento sin perder demasiada información. A continuación se describen los resultados por modelo.

3.8.1. *k*-means

Se entrenaron modelos de *k*-means con $k \in \{2, 3, 4, 5\}$ tanto en el conjunto original como en el transformado por *PCA*. Se revaluaron el coeficiente de *silhouette* y el gráfico del codo para cada k . Como era esperable, el mejor *silhouette* promedio se obtuvo con $k = 2$, aunque con valores bajos; el gráfico del codo mostró una reducción marcada de la inercia al aumentar k , con un codo en torno a $k = 4$, comportamiento consistente en

ambos conjuntos. Para la evaluación supervisada, se asignaron etiquetas a los grupos por mayoría y se calcularon matriz de confusión, precisión y exactitud. La figura 11 muestra las matrices de confusión para $k = 2$ en ambos conjuntos.




Figura 11: Matrices de confusión para k -means con $k = 2$.

Como se observa en el gráfico anterior, ambos modelos de k -means producen clasificaciones idénticas: el conjunto transformado por *PCA* no muestra mejoras frente al conjunto original. La exactitud global es baja porque el clasificador asigna todos los datos etiquetados a una sola clase (1). En consecuencia, recupera correctamente todos los ejemplos de la clase 1 ($\text{recall} = 1$), pero comete todos los falsos positivos sobre la clase -1 . Cabe aclarar, que el número de datos clasificados no llega a 1000, pues algunos puntos quedaron fuera del conjunto tras el filtrado por *IQR*.

3.8.2. Agrupamiento jerárquico

Se repitió el procedimiento de agrupamiento jerárquico sobre `x_total_filtrado` y `combined_x_PCA_df`, utilizando los criterios de enlace *ward* y *average*. Aunque el análisis preliminar sugería $k = 2$ como valor óptimo por *silhouette*, se evaluó $k \in \{2, \dots, 6\}$ para observar el comportamiento, dado que los dendrogramas indicaban posibles cortes en $k = 3$ – 5 . Como antes, se asignaron etiquetas por mayoría y se calcularon las métricas de clasificación (precisión, exactitud y matriz de confusión). Aun cuando los valores de *silhouette* fueron bajos, el desempeño en clasificación mejoró al incrementar k ; a partir de $k = 4$ – 6 ya no hubo mejoras adicionales ni cambios en la asignación, por lo que se eligió $k = 4$ como configuración final, pese a mantener *silhouette* bajo. En todas las comparaciones, `x_total_filtrado` superó al conjunto transformado por *PCA*, y el mejor enlace en ambos casos fue *ward*. La figura 12 muestra las matrices de confusión para $k = 4$ en ambos conjuntos.




Figura 12: Matriz de confusión mejor modelo de agrupación jerárquico.

El modelo jerárquico sobre `x_total_filtrado`, con enlace *ward* y $k = 4$, presenta falsos positivos en ambas clases particularmente en la clase -1 , pero aun así alcanza métricas de clasificación satisfactorias, como se muestra en la tabla 3.

Métrica	Valor
Silhouette	0.0442
Exactitud (Accuracy)	0.7753
Precisión (Macro)	0.7797
Exactitud clase -1	0.8369
Exactitud clase 1	0.7209

Tabla 3: Agrupamiento jerárquico (*ward*) con $k = 4$: métricas de desempeño.

3.8.3. DBSCAN

De acuerdo con la exploración inicial, *DBSCAN* no separó adecuadamente los datos en el espacio original de 20 dimensiones. Al repetir el procedimiento sobre `combined_x_pca_df`, se exploró $\varepsilon \in [4, 5, 5, 0]$ y `min_samples` $\in \{5, 8, 10, 12, 16\}$, incluyendo valores más altos para forzar grupos más densos, así como la distancia de coseno. Sin embargo, los resultados no mejoraron: se obtuvo nuevamente un único *cluster*, lo que impide calcular el coeficiente de *silhouette* y, como era de esperarse, el desempeño en clasificación equivale a asignar todas las muestras a la clase mayoritaria (1). Cabe aclarar que también se probó *DBSCAN* sobre `x_total_filtrado` y variando ε , sin mejoras: se seguía obteniendo un solo *cluster* o, en su defecto, la mayoría de las muestras quedaban marcadas como ruido.

3.8.4. SOM: Mapa autorganizado

En cuanto al *SOM*, se retomó el modelo entrenado con retícula 30×30 sobre los conjuntos que se han venido trabajando en esta sección. Las neuronas se etiquetaron por *voto mayoritario* con base en las muestras etiquetadas que mapeó cada BMU, y luego se evaluó la clasificación en el subconjunto etiquetado. Como se vaticinó en la exploración inicial, el método de agrupamiento basado en *SOM* resultó en el que mejor desempeño de clasificación alcanzó, superando a los demás modelos, específicamente con el conjunto `combined_x_PCA_df`. La figura 13 muestra la matriz de confusión obtenida.




Figura 13: Matriz de confusión mejor modelo *SOM*.

Este modelo de agrupación basado en *SOM* alcanzó métricas de clasificación satisfactorias, como se muestra en la tabla 4.

Métrica	Valor
Exactitud (Accuracy)	0.8202
Precisión (Macro)	0.8197
Recall (Macro)	0.8191
F1 (Macro)	0.8193
Exactitud balanceada	0.8191
Exactitud clase -1	0.8010
Exactitud clase 1	0.8372

Tabla 4: Métricas de desempeño mejor modelo *SOM*.

4. Entregable

De acuerdo con el análisis realizado, se selecciona el modelo de agrupamiento basado en *SOM* como el más representativo del conjunto de datos, utilizando como variables de entrada las 15 primeras componentes principales obtenidas por *PCA*. Como entregable, se genera el vector de etiquetas para todo el conjunto `x_prueba`, asignadas por el modelo seleccionado; este archivo es de tipo *CSV* y corresponde a un vector columna de tamaño 1×10000 (una etiqueta por registro). Sin embargo, y para mayor claridad, se incluye también la matriz `x_prueba` junto con sus etiquetas asignadas, resultando en un archivo *CSV* de tamaño 10000×21 (20 variables + 1 etiqueta), con el fin de evitar problemas de correspondencia entre archivos. El vector y la matriz se llaman respectivamente `som_etiquetas.csv` y `x_prueba_som_etiquetas.csv`.

5. Conclusiones

1. El conjunto de datos analizado presenta una estructura que dificulta la tarea de agrupamiento. Las causas pueden ser múltiples: desde la naturaleza intrínseca de las observaciones y la falta de información contextual sobre las variables, hasta posibles sesgos en el conjunto etiquetado que no reflejan fielmente la estructura latente.
2. Es posible que las clases del conjunto etiquetado hayan sesgado los análisis y la propuesta de modelos de agrupamiento. De hecho, en la fase de exploración los mejores resultados se obtuvieron con $k = 2$, incluso en el análisis de *PCA*, se observó que las dos primeras componentes eran las de mayor aporte relativo. En otras palabras, el hecho de observar dos clases y de que la exploración favoreciera $k = 2$ pudo llevar a asumir quizá de forma indebida que existen dos grupos “naturales” en los datos, cuando podría no ser así.
3. El análisis de correlación indicó que las variables no exhiben relaciones lineales fuertes entre sí, lo que sugiere baja redundancia. En consecuencia, la reducción de dimensionalidad mediante *PCA* puede no resultar especialmente ventajosa en todos los casos, pues puede conllevar pérdida de información relevante. Sin embargo, en este estudio, el uso de *PCA* contribuyó a mejorar el desempeño de clasificación del modelo basado en *SOM*.
4. El agrupamiento jerárquico mostró que, al aumentar el número de grupos k , mejoraba el desempeño en clasificación; esto sugiere que también pudo haberse explorado un k mayor en la fase supervisada con *k-means*. Sin embargo, con las herramientas disponibles (gráfico del codo e índice de *silhouette*) no es posible establecer *a priori* si el conjunto de datos contiene realmente más de dos grupos, teniendo en cuenta la alta dimensionalidad del conjunto de datos que se trabajó.
5. En general, los modelos de agrupamiento no supervisado tradicionales probados no lograron separar claramente los datos, lo que se refleja especialmente en los bajos valores de *silhouette* obtenidos. No obstante, al evaluar el desempeño supervisado, algunos modelos (especialmente el jerárquico con $k = 4$) alcanzaron métricas de clasificación aceptables, lo que sugiere que las métricas de agrupamiento no supervisado no siempre reflejan el potencial de clasificación de los modelos, es importante no desechar un modelo únicamente por sus bajos valores de *silhouette*.